

בניית מודל חיזוי - דירוג סרטים

מטלת סיכום - חלק 2 | קורס למידת מכונה

שמות המגישות: זוהר קולפ ורוני פחימה

1. תיאור הדאטה המעובד וטבלת הפיצרים

הדאטה בפרויקט מבוסס על מאגר הסרטים של IMDb שנבנה בחלק הראשון של המטלה. מטרת המודל היא לחזות את דירוג הסרט הממוצע (averageRating) עוד לפני יציאתו לאקרנים, תוך שימוש במידע הזמין בזמן יציאת הסרט בלבד. לאחר תהליך ניקוי והנדסת פיצרים, התקבל סט נתונים הכולל 115,560 סרטים ו-16 פיצרים המשמשים כמשתני קלט למודלים. משתנה המטרה הוא: averageRating, אשר מייצג את הדירוג הממוצע של הסרט בטווח 1-10.

טבלת הפיצרים

פיצר	סוג הפיצר	נוסחה/ תיאור	מוטיבציה
startYear	נומרי	שנת יציאת הסרט	סרטים ישנים מדורגים אחרת מחדשים
runtimeMinutes	נומרי	זמן ריצה בדקות (30-600)	סרטים ארוכים נוטים לדירוגים גבוהים יותר
num_genres	נומרי	מספר הז'אנרים לסרט	סרטים רב-ז'אנריים שונים בתפיסה מסרטים פשוטים
runtime_per_genre	נומרי מורכב (ratio)	runtimeMinutes / num_genres	מדד המשלב בין מורכבות הסרט לאורך שלו
is_drama / is_comedy / is_action / is_thriller / is_romance / is_horror / is_documentary / is_crime / is_adventure / is_animation	בינארי	1 אם הז'אנר מופיע ברשימת הז'אנרים של הסרט, אחרת 0	פיצרים אלו מאפשרים למודל ללמוד את ההשפעה הייחודית של כל ז'אנר על דירוג הסרט, שכן ז'אנרים שונים פונים לקהלי יעד שונים ומציגים דפוסי דירוג שונים ב-IMDb.
is_english	בינארי	1 אם אחת משפות הסרט היא English, אם קיימת שפה אחרת 0, ו-NaN כאשר מידע השפה חסר	סרטים באנגלית חשופים לקהל עולמי גדול יותר
is_us	בינארי	1 אם מדינת המקור היא ארצות הברית, 0 אם מדינת המקור אינה ארצות הברית, ו-NaN כאשר מידע המדינה חסר	סרטים אמריקאיים נהנים לרוב מחשיפה בינלאומית רחבה יותר ומשאבי הפקה גדולים יותר, ולכן עשויים לקבל דפוסי דירוג שונים

שלבי פונקציית prepare_data

פונקציית prepare_data אחראית על ניקוי הנתונים, הנדסת הפיצרים והכנת מערך הקלט למודלי החיזוי. התהליך כולל את השלבים הבאים:

שלב 1 - ניקוי ערכים חריגים וחסרים:

ערכים המשמשים לייצוג מידע חסר או לא תקין (כגון N/A, NULL, NaN) מחרוזות ריקות וערכים דומים נוספים) הומרו ל- NaN לצורך טיפול אחיד במידע חסר.

שלב 2 - טיפול במשתנים נומריים:

העמודות startYear ו runtimeMinutes הומרו לערכים נומריים. בנוסף, בוצעה בקרת תקינות לשנות היציאה, כך שערכים לא הגיוניים (0, שנים מוקדמות מ-1888 או מאוחרות מ-2026) סומנו כערכים חסרים.

שלב 3 - עיבוד עמודת הז'אנרים:

עמודת genres הומרה לרשימת ז'אנרים אחידה עבור כל סרט. התהליך תמך במספר פורמטים אפשריים של הנתונים, כולל מחרוזות בודדות ורשימות, תוך שימוש ב- ast.literal_eval בעת הצורך.

שלב 4 - יצירת פיצ'רי ז'אנרים בינאריים:

נוצרו משתנים בינאריים עבור עשרה ז'אנרים:

Drama, Comedy, Action, Thriller, Romance, Horror, Documentary, Crime, Adventure, Animation.

כל פיצ'ר מקבל ערך 1 אם הז'אנר מופיע ברשימת הז'אנרים של הסרט, ו-0 אחרת.

שלב 5 - יצירת פיצ'רים חדשים:

נוצרו שני פיצ'רים נוספים num_genres המייצג את מספר הז'אנרים של הסרט, ו runtime_per_genre פיצ'ר מורכב המחושב כיחס בין אורך הסרט לבין מספר הז'אנרים שלו.

שלב 6 - יצירת פיצ'ר שפה:

נוצר הפיצ'ר is_english המציין האם אחת משפות הסרט היא אנגלית, כאשר מידע השפה חסר, הערך נשאר NaN ומטופל בהמשך בתוך ה-Pipeline.

שלב 7 - יצירת פיצ'ר מדינת מקור:

נוצר הפיצ'ר is_us, המציין האם מדינת המקור של הסרט היא ארצות הברית. הזיהוי בוצע תוך תמיכה במספר וריאציות כתיבה נפוצות כגון USA, U.S.A, U.S. ו-United States. כאשר מידע השפה חסר, הערך נשאר NaN ומטופל בהמשך בתוך ה-Pipeline.

שלב 8 - בחירת הפיצ'רים הסופיים ובדיקת תקינות:

בסיום התהליך נשמרו 16 הפיצ'רים הסופיים המשמשים את המודלים. בנוסף בוצעה בדיקת תקינות (Safety Check) המוודאת שכל העמודות הנדרשות קיימות לפני החזרת מערך הנתונים הסופי, אם עמודה חסרה היא נוצרת עם ערכי NaN. כמו כן, נוספה בדיקת Leakage guard המוודאת שעמודות אסורות כגון: averageRating, numVotes ו-BoxOffice אינן נכללות בפיצ'רים של המודל.

השוואת המודלים

לצורך חיזוי דירוג הסרטים נבנו והשוו שני מודלים שונים Elastic Net ו-Random Forest שני המודלים הוערכו באמצעות 10-Fold Cross Validation ובחירת ההיפר-פרמטרים בוצעה באמצעות Grid Search.

מודל Elastic Net:

הוא מודל רגרסיה לינארי המשלב רגולריזציות L1 ו-L2. שילוב זה מאפשר להתמודד עם קורלציות בין פיצ'רים, לצמצם Overfitting ולשמור על מודל בעל פרשנות גבוהה.

לצורך בחירת ההיפר-פרמטרים בוצע Grid Search על הפרמטרים:

• $\alpha = [0.0001, 0.001, 0.01, 0.1, 1.0]$

• $l1_ratio = [0.1, 0.3, 0.5, 0.7, 0.9]$

הפרמטרים האופטימליים שנבחרו היו:

• $\alpha = 0.001$

• $l1_ratio = 0.1$

מודל Random Forest:

הוא מודל המבוסס על אוסף של עצי החלטה, אשר מפיקים יחד תחזית סופית. המודל נבחר לפרויקט משום שהוא מסוגל לזהות דפוסים מורכבים וקשרים שאינם לינאריים בין מאפייני הסרטים לבין הדירוג, ובכך מהווה השלמה טובה למודל Elastic Net הלינארי.

לצורך בחירת ההיפר-פרמטרים בוצע Grid Search על הפרמטרים:

• $n_estimators = [100, 200, 300]$

• $max_depth = [10, 20, None]$

• $min_samples_split = [2, 5, 10]$

הפרמטרים האופטימליים שנבחרו היו:

• $n_estimators = 300$

• $max_depth = 10$

• $min_samples_split = 10$

תוצאות 10 - Fold Cross Validation

Model	RMSE	MAE	R ²
Elastic Net	1.1366	0.8706	0.2269
Random Forest	1.1090	0.8444	0.2641

ניתוח התוצאות

ניתן לראות כי מודל Random Forest השיג את הביצועים הטובים ביותר בכל מדדי ההערכה. בהשוואה ל- Elastic Net הוא הפחית את שגיאת ה-RMSE מ-1.1366 ל-1.1090 ואת שגיאת ה-MAE מ-0.8706 ל-0.8444. בנוסף, ערך ה- R^2 עלה מ-0.2269 ל-0.2641, דבר המעיד על יכולת טובה יותר להסביר את השונות בדירוגי הסרטים. תוצאה זו מצביעה על כך שהקשר בין מאפייני הסרטים לבין הדירוג אינו לינארי לחלוטין. בעוד שמודל Elastic Net מצליח ללכוד מגמות כלליות בדאטה, מודל Random Forest מסוגל לזהות אינטראקציות מורכבות יותר בין הפיצורים השונים ולכן מספק תחזיות מדויקות יותר. בנוסף, סטיות התקן הנמוכות שהתקבלו עבור שני המודלים מעידות על יציבות גבוהה של הביצועים לאורך 10 ה-Folds ועל כך שהתוצאות אינן תלויות בחלוקה מסוימת של הדאטה. לאור ביצועיו העדיפים בכל המדדים, נבחר מודל Random Forest כמודל המרכזי להמשך הניתוחים בפרויקט.

ניתוח חשיבות פיצורים

לצורך הבנת הגורמים המשפיעים ביותר על חיזוי דירוג הסרטים, בוצע ניתוח חשיבות פיצורים עבור שני המודלים. במודל Elastic Net נמדדה החשיבות באמצעות גודל המקדמים הסטנדרטיים, ואילו במודל Random Forest נעשה שימוש ב-Permutation Importance.

הפיצורים החשובים ביותר עבור כל מודל וכיוונום:

פיצור	כיוון (Elastic Net)	כיוון (SHAP – Random Forest)
is_documentary	חיובי	חיובי
runtimeMinutes	חיובי	חיובי
is_horror	שלילי	שלילי
is_drama	חיובי	חיובי
is_action	שלילי	לא ב-Top 5
startYear	לא ב-Top 5	שלילי (שנים חדשות)

בנספח ב' מצורף גרף SHAP Summary של מודל Random Forest, אשר שימש לקביעת כיוון ההשפעה של הפיצורים החשובים על תחזיות המודל.

השוואה בין המודלים

שני המודלים מסכימים על 4 מתוך 5 הפיצורים החשובים ביותר: is_documentary, is_horror, is_drama, runtimeMinutes וכן על הכיוון ההשפעה שלהם. הסכמה זו מחזקת את המסקנה שמדובר בפיצורים בעלי השפעה משמעותית ויציבה על הדירוג. הפיצור שמפצל בין המודלים הוא is_action במודל Elastic Net לעומת startYear במודל Random Forest. ייתכן כי פיצול זה נובע מכך ש- Elastic Net מזהה בעיקר קשרים ליניאריים ישירים, ולכן בחר ב-is_action בעוד Random Forest מסוגל לזהות דפוסים מורכבים יותר ואינטראקציות בין משתנים, ולכן זיהה את startYear כפיצור חשוב. ממצא זה מרמז כי להשפעת שנת ההפקה על דירוג הסרט קיימים דפוסים שאינם ליניאריים בלבד.

5. ניתוח שגיאות - Error Analysis 5.1 חילוף 20 ה - Random Forest - Outliers

מצורפות הטבלאות בנספח א'.

5.2 ניתוח איכותי

ניתוח 5 סרטים ספציפיים

Horseplay: The History of Horse Riding (2021)

דירוג אמיתי: 1.0 | דירוג חזוי: 7.18

סרט אנימציה-דוקומנטרי העוסק בהיסטוריה של רכיבה על סוסים. ייתכן שהמודל טעה משום שלמד שסרטים דוקומנטריים נוטים לקבל דירוגים גבוהים יחסית ולכן העריך את הסרט ביתר. מאפיין ייחודי אפשרי - שילוב של הזאנרים Animation ו- Documentary עבור קהל יעד ספציפי.

Justin Bieber: Always Believing (2012)

דירוג אמיתי: 1.0 | דירוג חזוי: 7.18

סרט Documentary/Music המתאר את עלייתו של אמן פופ מפורסם להצלחה בינלאומית. המודל למד שסרטי Documentary ו- Music נוטים לקבל דירוגים גבוהים יחסית ולכן חזה דירוג של 7.18. עם זאת, ייתכן שסרטים העוסקים באמנים בעלי קהל מקוטב מעוררים תגובות קיצוניות מצד צופים, תופעה שאינה מיוצגת בפיצורים של המודל. מאפיין ייחודי אפשרי הוא שיוך לאמן בעל קהל אוהדים ומבקרים משמעותי, מידע שאינו מיוצג במאפייני המודל.

Halloween Deluxe (2019)

דירוג אמיתי: 9.1 | דירוג חזוי: 4.44

סרט Horror שקיבל דירוג גבוה במיוחד. סביר להניח כי המודל חזה דירוג נמוך משום שלמד שבממוצע סרטי אימה מדורגים נמוך יותר. מאפיין ייחודי אפשרי הוא שמדובר בסרט אימה בעל קהל מעריצים נאמן במיוחד, שדחף את הדירוג לרמה חריגה ביחס לז'אנר.

Of Sound Mind Of Sound Mind (2015)

דירוג אמיתי: 9.6 | דירוג חזוי: 5.21

סרט Romance/Thriller בעל דירוג גבוה במיוחד. ניתן לשער כי המודל חזה דירוג הקרוב לממוצע של הז'אנרים הללו ולא זיהה שמדובר במקרה חריג ביחס להתפלגות הרגילה שלהם. מאפיין ייחודי אפשרי הוא קהל נישה שהעניק לסרט דירוגים גבוהים במיוחד, מידע שאינו קיים במאפייני המודל.

Jasenovac: Istina (2016)

דירוג אמיתי: 1.4 | דירוג חזוי: 7.16

סרט Documentary/History העוסק בנושא היסטורי רגיש מתקופת מלחמת העולם השנייה וקיבל דירוג נמוך מאוד למרות השתייכותו לז'אנרים שבדרך כלל מדורגים גבוה. ניתן לשער כי המודל הסתמך על הקשר החיובי שנלמד עבור סרטים דוקומנטריים והיסטוריים ולכן העריך את הסרט ביתר. מאפיין ייחודי אפשרי הוא שהסרט עוסק בנושא שנוי במחלוקת, אשר עשוי היה להשפיע על דירוגי הצופים ולהוביל לתוצאה חריגה ביחס לסרטים דומים.

זיהוי דפוסים משותפים

ניתוח כלל 20 ה - Outliers חשף דפוס ברור ברמת הז'אנר. כל עשרת סרטי ה - Overprediction כללו את הז'אנר Documentary, בעוד שבקבוצת ה - Underprediction, הופיעו בעיקר הז'אנרים Horror ו- Thriller. בנוסף, הדירוג האמיתי הממוצע של סרטי ה - Overprediction היה 1.36 בלבד, בעוד שהמודל חזה עבורם דירוג ממוצע של 7.24. לעומת זאת, סרטי ה - Underprediction קיבלו דירוג אמיתי ממוצע של 9.16, אך המודל חזה עבורם דירוג ממוצע של 4.65 בלבד.

ממצא זה מעיד כי המודל למד היטב את ההתנהגות הממוצעת של הז'אנרים השונים, אך התקשה לזהות מקרים חריגים הסוטים באופן משמעותי מהדפוס המקובל. סרטים דוקומנטריים בעלי דירוג נמוך במיוחד זוהו בטעות כסרטים איכותיים, בעוד שסרטי Horror ו- Thriller בעלי דירוג גבוה במיוחד זוהו בטעות כסרטים בעלי דירוג נמוך.

נבדקו גם מאפיינים נוספים כגון שנת יציאה, זמן ריצה, מספר ז'אנרים ו- runtime_per_genre ולא נמצאו הבדלים עקביים בין קבוצות ה - Overprediction וה - Underprediction במאפיינים אלו. לכן נראה כי מקור השגיאות המרכזי אינו במאפיינים המבניים של הסרט אלא בעיקר בדפוסים הקשורים לז'אנר ובמקרים חריגים הסוטים מההתנהגות הממוצעת של הז'אנר אליו הם שייכים.

5.3 השוואה בין מודלים

חולצו 20 ה - Outliers הגדולים ביותר מכל מודל (Overprediction 10 ו-Underprediction 10) נמצא כי 11 מתוך 20 הסרטים (55%) היו משותפים לשני המודלים, דבר המעיד כי מדובר במקרים שקשים לחיזוי ללא קשר לסוג המודל.

כאשר Elastic Net נכשל, Random Forest הצליח להתמודד טוב יותר עם אותם סרטים והפחית את השגיאה הממוצעת בכ-15% (4.262 לעומת 5.014). באופן דומה, כאשר Random Forest נכשל Elastic Net, הפחית את השגיאה הממוצעת בכ-9% (4.417 לעומת 4.854).

ממצאים אלו מצביעים על כך שהמודלים אינם מבצעים בדיוק את אותן טעויות, אלא לומדים דפוסים שונים ומשלימים זה את זה במידה מסוימת. עם זאת, שני המודלים התקשו בעיקר עם סרטים בעלי דירוגים קיצוניים במיוחד, ובפרט סרטי Documentary בעלי דירוג נמוך מאוד וסרטי Horror ו-Thriller בעלי דירוג גבוה מאוד.

סוגי שגיאות ייחודים לכל מודל

שני המודלים הציגו דפוס דומה בשגיאות הייחודיות להם, עם 3 מקרי Overprediction ו-6 מקרי Underprediction לכל מודל. ממצא זה מעיד כי שני המודלים מתקשים יותר לחזות סרטים בעלי דירוג גבוה במיוחד מאשר סרטים בעלי דירוג נמוך. בנייתו ה - Shared Outliers נמצא כי Random Forest הציג שגיאות קטנות יותר ברוב מקרי ה -Overprediction, בעוד Elastic Net הציג שגיאות קטנות יותר ברוב מקרי ה-Underprediction.

5.4 הצעות לשיפור

על בסיס ניתוח השגיאות, הוצעו שני פיצ'רים חדשים שעשויים לסייע בהפחתת השגיאות שזוהו בשני המודלים.

פיצ'ר 1: documentary_subtype - תת - סוג של סרט דוקומנטרי

הבעיה שהוא פותר:

רבים מה - overpredictions הגדולים ביותר היו סרטי Documentary כגון: Justin Bieber, Ramo Trip Obama in NC, Always Believing, Tribalism Is Killing Us

כיום המודל משתמש רק בפיצ'ר is_documentary ולכן מתייחס לכל הסרטים הדוקומנטריים כקבוצה אחת. בפועל קיימים סוגים שונים של סרטים דוקומנטריים, כגון סרטים היסטוריים, מדעיים, ביוגרפיים או סרטים בעלי אופי פרסומי, ולכן המודל לומד דפוס כללי של Documentary ומנבא באופן דומה לכל הסרטים בקטגוריה.

מה הפיצ'ר מוסיף: סיווג הסרט לתת-קטגוריה כגון Historical, Scientific, Nature, Biography או Music Documentary על בסיס עמודת plot.

למה הוא עשוי לשפר את המודל: הפיצ'ר יאפשר למודל להבחין בין סוגים שונים של סרטים דוקומנטריים וללמוד דפוס דירוג שונים עבור כל סוג.

פיצ'ר 2: horror_has_franchise - האם סרט Horror שייך לסדרת סרטים מוכרת

הבעיה שהוא פותר: רבים מה - underpredictions הגדולים ביותר היו סרטי Horror כגון: Ice Nine Kills, Halloween Deluxe, Oscuro ו-Son-nim-1. נראה כי המודלים למדו שסרטי Horror נוטים לקבל דירוג נמוך במוצג, אך אינם מבחינים בין סרט אימה עצמאי לבין סרט השייך לסדרת סרטים מוכרת (Franchise).

מה הפיצ'ר מוסיף: סימון האם הסרט הוא חלק מסדרת סרטים קיימת או פרנצ'ייז מוכר, למשל באמצעות זיהוי מספרי המשך או מילות מפתח אופייניות בשם הסרט.


למה הוא עשוי לשפר את המודל: סרטי המשך נהנים לעיתים מקהל קיים שכבר מכיר את המותג ואת סדרת הסרטים, ולכן עשויים לקבל דירוג גבוה יותר מסרט Horror ממוצע. מידע זה יכול לסייע למודל לזהות מקרים שבהם דירוג הסרט צפוי להיות גבוה מהמקובל בז'אנר.

6. ניתוח הוגנות - Fairness Analysis


מטרת הניתוח היא לבחון האם המודל מספק רמת דיוק דומה עבור קבוצות שונות של סרטים, או שקיימות אוכלוסיות מסוימות שעליהן המודל מדויק יותר או פחות. הניתוח בוצע על מודל Random Forest שנבחר כמודל הסופי. בהתאם להנחיות המטלה, נבחרו שני חתכים: לפי ז'אנר ולפי עשור יציאה.

חתך 1 - לפי ז'אנר

חמשת הז'אנרים הנפוצים ביותר בדאטה הם Drama, Comedy, Romance, Action, Documentary.



חתך 2 - לפי עשור יציאה



דין

האם יש חתכים בהם המודל משמעותית פחות מדויק?

כן. בחתך הז'אנר Action, מציג את שגיאת החיזוי הגבוהה ביותר ($RMSE=1.2024$), כ-8.4% מעל הממוצע הכללי (1.1090) וכ-21% גבוה מ-Documentary. בחתך העשורים, סרטים משנות ה-2020 מציגים את הביצועים החלשים ביותר ($RMSE=1.2380$), כ-56% גבוה מסרטי שנות ה-1940 ($RMSE=0.7949$). לכן ניתן להסיק כי המודל פחות מדויק עבור סרטים חדשים בהשוואה לסרטים ישנים.

האם יש הסבר למה?

לגבי Action, ייתכן שהסיבה לכך היא שדירוגם של סרטי Action מושפע ממספר רב של גורמים, כגון תקציב ההפקה, מאפייני צוות השחקנים והעדפות קהל ייחודיות לז'אנר. כתוצאה מכך, הקשרים בין הפיצ'ר לבין הדירוג עשויים להיות מורכבים יותר, ולכן המודל מתקשה לחזות את דירוגם באותה רמת דיוק המתקבלת בז'אנרים אחרים.

לגבי העשורים החדשים - סרטים חדשים מושפעים ממגמות עדכניות, פלטפורמות סטרימינג, שינויי העדפות קהל ותחרות רבה יותר, גורמים שאינם מיוצגים באופן מלא בפיצ'רים הזמינים למודל. לעומת זאת, סרטים ישנים ששרדו במאגרי הדירוג נוטים להיות סרטים ידועים עם התפלגות דירוגים יציבה.

האם זה מעלה חששות לגבי שימוש במודל בפועל? על אילו סרטים לא הייתם סומכים בחיזוי?

ממצאי ניתוח ההוגנות מעלים חששות מסוימים לגבי אמינות המודל בקבוצות מסוימות. סרטי Action וסרטים מהעשורים החדשים מציגים את רמות השגיאה הגבוהות ביותר, ולכן התחזיות עבור קבוצות אלו עשויות להיות פחות מהימנות בהשוואה לשאר הקבוצות שנבדקו. בנוסף, עבור עשורים בעלי ייצוג נמוך מאוד למשל שנות ה-1910 עם $N=171$ למרות שהשגיאה המחושבת נמוכה יחסית, גודל המדגם מקשה על הסקת מסקנות אמינות. לעומת זאת, עבור סרטי Documentary ו-Romance וכן עבור סרטים מעשורים מוקדמים יותר, המודל מציג ביצועים יציבים ומדויקים יותר.

האם Missingness עשויה להיות מנבאת? האם הן משתלבות עם Bais מסוים?

כן, היעדר מידע אינו בהכרח אקראי, ולעיתים עצם קיומו של ערך חסר עשוי לשקף מאפיינים מסוימים של הסרט. ייתכן שחוסר במידע על שפה או מדינת מקור קשור לרמת התייעוד של הסרט, לשנת ההפקה שלו או למאפיינים אחרים שאינם נמדדים ישירות במודל. במקרים כאלה, דפוס החסרים עצמו עשוי להכיל מידע שימושי לחיזוי הדירוג, ולכן שימוש ב-Missing Indicators יכול לסייע למודל לנצל מידע זה. עם זאת, קיים גם סיכון להטיה (Bias), שכן המודל עלול ללמוד קשרים הנובעים מאיכות או זמינות המידע במאגר הנתונים ולא ממאפייניו האמיתיים של הסרט. לכן, יש לשקול את השימוש ב-Missing Indicators תוך הבנה שהם עשויים לשפר את הביצועים מצד אחד, אך גם להכניס הטיית לא רצויות מצד שני.

מניעת Data Leakage

במהלך הפרויקט ננקטו מספר צעדים למניעת דליפת מידע (Data Leakage), במטרה להבטיח שהמודלים יוערכו באופן הוגן על נתונים שלא נחשפו אליהם במהלך האימון.

שדות שהוסרו מהמודל:

שדה	סיבת הסרה
averageRating	משתנה המטרה אותו נדרש לחזות
numVotes	מספר ההצבעות מצטבר לאחר יציאת הסרט ולכן אינו ידוע מראש
BoxOffice	הכנסות הסרט ידועות רק לאחר יציאתו לאקרנים

בנוסף, משתנה המטרה averageRating, נשמר אך ורק ב-y ולא נכלל ב-X, כך שהמודל לא נחשף לערך אותו הוא נדרש לחזות. לאחר הסרת סרטים ללא דירוג, בוצעה התאמה מלאה בין X ל-y באמצעות האינדקסים.

שימוש ב-Pipeline

כל שלבי ה-Preprocessing, לרבות השלמת ערכים חסרים באמצעות SimpleImputer ונרמול באמצעות StandardScaler, הוגדרו בתוך Pipeline והועברו ל-GridSearchCV כמודל מלא.

בכל Fold:

- ה-Imputer וה-Scaler מבצעים fit על נתוני האימון בלבד.
- נתוני ה-Validation עוברים transform בלבד.

גישה זו מונעת דליפת מידע מקבוצת הבדיקה ומבטיחה הערכת ביצועים אמינה

מסקנות:

מודל Random Forest השיג ביצועים טובים יותר ממודל Elastic Net בכל מדדי ההערכה במסגרת 10 - Fold Cross Validation דבר המעיד כי הקשרים בין מאפייני הסרט לבין הדירוג אינם ליניאריים בלבד.

ניתוח חשיבות הפיצ'רים הראה הסכמה גבוהה בין המודלים, כאשר: is_documentary, is_horror ו runtimeMinutes - is_drama זוהו כפיצ'רים מרכזיים בשניהם. סרטים דוקומנטריים, סרטי דרמה וסרטים ארוכים יותר נוטים לקבל דירוג חזוי גבוה יותר, בעוד שסרטי אימה נוטים לקבל דירוג חזוי נמוך יותר. בנוסף Random Forest, זיהה את startYear כפיצ'ר חשוב, כאשר סרטים משנים מוקדמות יותר נוטים לקבל דירוג חזוי גבוה יותר.

ניתוח השגיאות הראה כי שני המודלים מתקשים במיוחד בחיזוי סרטים בעלי דירוגים קיצוניים, ונמצאה חפיפה גבוהה בין ה-Outliers של שני המודלים, דבר המצביע על מגבלות המידע הקיים בדאטה ועל פוטנציאל לשיפור באמצעות פיצ'רים נוספים.

כמו כן, נמצא כי ביצועי המודל אינם אחידים עבור כלל הקבוצות בדאטה. סרטים חדשים וסרטי Action הציגו רמות שגיאה גבוהות יותר בהשוואה לקבוצות אחרות, דבר המצביע על כך שחיזוי הדירוג עבור קבוצות אלו מאתגר יותר.

מגבלות:

- אחוז גבוה מהסרטים מכיל מידע חסר בשדות Country ו Language, דבר המגביל את תרומת הפיצ'רים is_english ו is_us.
- פיצ'רי הז'אנר נבנו בצורה בינארית בלבד. לדוגמה is_documentary, אינו מבחין בין סוגים שונים של סרטים תיעודיים.
- גורמים נוספים שעשויים להשפיע על הדירוג, כגון מאפייני שחקנים, במאים ותוכן העלילה, אינם מיוצגים במודל.
- המשתנים numVotes ו BoxOffice לא נכללו במודל מאחר שהם משקפים מידע המצטבר לאחר יציאת הסרט. אף שהיו עשויים לשפר את ביצועי החיזוי, השימוש בהם היה פוגע ביכולת להעריך את דירוג הסרט על בסיס מידע הזמין בזמן החיזוי בלבד.
- המודל מדויק פחות עבור סרטים חדשים (משנות 2010 ואילך) ועבור סרטי Action, כפי שנמצא בניתוח ההוגנות.

הצעות להמשך:

- פיתוח פיצ'רים מבוססי טקסט מתוך plot, כגון זיהוי תתי-קטגוריות של סרטי Documentary או Horror.
- בחינה מעמיקה יותר של שילוב מידע על במאים ושחקנים באופן שאינו יוצר Data Leakage.
- הרחבת הפיצ'רים באמצעות נתונים חיצוניים כגון פרסים, מועמדות ומידע על תהליך ההפקה.
- פיתוח פיצ'רים ייעודיים עבור קבוצות שבהן המודל התקשה יותר, כגון סרטי Action וסרטים חדשים.

AI Usage Log

נושא	שימוש	אימות
prepare_data	התייעצות לגבי טיפול בפורמטים שונים של genres וכתובת פונקציות עיבוד נתונים	הפיצ'רים והקוד נבדקו באמצעות הרצה על הדאטה ובחינת הפלט
Pipeline, ColumnTransformer	קבלת הסברים על Data Leakage וביצוע Cross Validation תקין	נבדק כי כל שלבי ה-Preprocessing בוצעו בתוך ה-Pipeline
Error Analysis	התייעצות לגבי פרשנות חריגים (Outliers) ודפוסי שגיאה במודלים	הממצאים נבדקו מול פלטי cross_val_predict ותוצאות החיזוי שהתקבלו בפועל
Fairness Analysis	התייעצות לגבי בחירת חתכים ופרשנות התוצאות	הקוד נכתב והורץ על נתוני הפרויקט, והתוצאות נבדקו מול הפלטים שהתקבלו.
Feature Importance	הסבר על Permutation Importance ופרשנות חשיבות הפיצ'רים	ההסברים נבדקו מול גרף ה-SHAP ופלטי המודל שהתקבלו.

נספח א' - נספח א' מציג את 20 מקרי השגיאה הקיצוניים ביותר Overprediction ו-10 נספח א' - נספח א' מציג את 20 מקרי השגיאה הקיצוניים ביותר Underprediction של מודל Random Forest, במסגרת ה-Cross Validation

=== 10 Overprediction ===

	primaryTitle	true_rating	pred_rating	error	startYear	genres
12464	Justin Bieber: Always Believing	1.0	7.18	6.18	2012.0	Documentary,Music
133563	Horseplay: The History of Horse Riding	1.0	7.18	6.18	2021.0	Animation,Documentary
16815	Kurz	1.2	7.20	6.00	2023.0	Documentary
52582	Rape of the Soul	1.7	7.69	5.99	2006.0	['Documentary', 'History']
52638	Ramo Trip	1.4	7.23	5.83	2012.0	['Documentary']
72010	Tribalism Is Killing Us	1.3	7.09	5.79	2019.0	['Documentary']
37806	Obama in NC: The Path to History	1.5	7.28	5.78	2010.0	['Documentary']
10554	Jasenovac: Istina	1.4	7.16	5.76	2016.0	Documentary,History,Mystery
104680	Brush with Life: The Art of Being Edward Biberman	1.5	7.17	5.67	2007.0	['Documentary']
12021	Justin Bieber's Believe	1.6	7.26	5.66	2013.0	Documentary,Music

=== 10 Underprediction ===

	primaryTitle	true_rating	pred_rating	error	startYear	genres
106898	Bukunja Tekunja Mitti: The Cannibals	9.1	4.35	-4.75	2012.0	['Action', 'Horror']
57344	Son-nim-1 Cheo-beon-jjae I-ya-gi	9.1	4.37	-4.73	2011.0	Horror,Thriller
78652	Ungleich	9.1	4.41	-4.69	2013.0	['Fantasy', 'Horror']
131379	Halloween Deluxe	9.1	4.44	-4.66	2019.0	Horror
36522	Oscuro by Rene Potter	8.6	4.04	-4.56	2016.0	['Horror']
38958	Of Sound Mind	9.6	5.21	-4.39	2015.0	['Romance', 'Thriller']
126114	Hasruin	9.6	5.25	-4.35	2020.0	Comedy,Drama,Thriller
1119	Ice Nine Kills Presents: Welcome to Horrorwood	8.4	4.08	-4.32	2024.0	Horror
43454	Puli Vachindi Meka Chachindi	9.5	5.18	-4.32	2021.0	Thriller
9295	Justicia Implacable	9.5	5.20	-4.30	2023.0	Action,Drama,Horror

נספח ב'

גרף ה - SHAP Summary

